

Hadoop DataNode

核心架构设计文档

基于 release-3.3.5-RC0 版本源码深度分析

项目	Apache Hadoop HDFS
模块	hadoop-hdfs / server / datanode
版本	release-3.3.5-RC0
范围	DataNode主目录+6个子目录(checker/erasurecode/fsdataset/impl/metrics/web)
文件数	131 个 Java 源文件
工具	自动化源码架构分析

目录

- 一、模块概述
- 二、核心六层服务架构
- 三、DataNode 启动流程与生命周期
- 四、块池管理层—BlockPoolManager/BPOfferService/BPServiceActor
- 五、数据传输层—DataXceiverServer/BlockReceiver/BlockSender
- 六、块存储层—FsDatasetSpi/FsDatasetImpl/副本类型体系
- 七、维护与扫描层—BlockScanner/DirectoryScanner/DiskBalancer
- 八、块恢复机制—BlockRecoveryWorker
- 九、高级特性—纠删码/短路读/FileIoProvider
- 十、核心流程时序分析
- 十一、设计模式总结
- 十二、关键场景调用链
- 十三、子目录概览与核心源文件清单
- 十四、设计亮点与总结

一、模块概述

DataNode 是 HDFS 分布式文件系统的数据存储节点，负责在本地磁盘上存储数据块（Block），响应客户端的读写请求，执行 NameNode 下发的块复制、删除、恢复等命令。模块位于 hadoop-hdfs/server/datanode 目录，包含 131 个 Java 源文件，覆盖根目录54个文件及 checker/、erasurecode/、fsdataset/、fsdataset/impl/、metrics/、web/ 等6个子目录。DataNode 采用门面模式作为统一入口，内部管理块池注册、数据传输、存储卷、块扫描、磁盘均衡、纠删码重构等子服务的完整生命周期。

1.1 核心职责

- 数据块存储：在多个存储卷（DISK/SSD/ARCHIVE/RAM_DISK）上管理数据块文件和校验文件
- 客户端数据读写：响应readBlock/writeBlock请求，支持pipeline写入和零拷贝读取
- 块池注册与心跳：向所有NameNode注册并定期发送心跳、块报告、增量块报告
- NameNode命令执行：执行复制(DNA_TRANSFER)、删除(DNA_INVALIDATE)、恢复(DNA_RECOVERBLOCK)等命令
- 块完整性校验：BlockScanner/VolumeScanner定期扫描数据块校验和，发现坏块上报NameNode
- 目录一致性扫描：DirectoryScanner定期比对磁盘文件与内存元数据的一致性
- 磁盘均衡：DiskBalancer在DataNode本地不同磁盘间移动块以平衡使用率
- 纠删码支持：ErasureCodingWorker/StripedReconstructor重构丢失的条带化数据块
- 短路读管理：ShortCircuitRegistry管理客户端短路读使用的共享内存段

1.2 模块目录结构

目录	文件数	核心职责
datanode/ (根目录)	54	DataNode主类、块池管理、数据传输、块恢复、存储位置等
checker/	3	存储位置检查器(StorageLocationChecker)
erasurecode/	10	纠删码工作器和条带化重构器
fsdataset/	28	块存储SPI接口和数据集抽象
fsdataset/impl/	25	FsDatasetImpl默认实现、卷管理、副本映射
metrics/	4	DataNode JMX指标收集
web/	7	DataNode Web UI资源和Servlet

二、核心六层服务架构

DataNode模块采用清晰的六层服务架构：门面层→块池管理层→数据传输层→块存储层→维护扫描层→高级特性层。每层职责分明，通过接口解耦。

2.1 六层架构全景图




图2-1：DataNode六层服务架构全景图

2.2 各层职责概述

层级	核心类	职责	设计模式
门面层	DataNode, DNConf, DataStorage	统一入口,管理所有子服务生命周期	门面模式
块池管理层	BlockPoolManager, BPOfferService, BPServiceActor	NN注册/心跳/块报告/HA切换	读写锁, 命令模式
数据传输层	DataXceiverServer, DataXceiver, BlockReceiver/Sender	TCP数据传输服务,读写块	Reactor模式, 职责链
块存储层	FsDatasetImpl, FsVolumeImpl, ReplicaMap	本地磁盘块管理,副本映射	SPI/策略/建造者模式
维护扫描层	BlockScanner, DirectoryScanner, DiskBalancer	块校验/目录一致性/磁盘均衡	观察者模式
高级特性层	ErasureCodingWorker, ShortCircuitRegistry	纠删码重构/短路读/IO代理	代理/装饰器模式

三、DataNode启动流程与生命周期

入口：DataNode.main() → secureMain() → createDataNode() → instantiateDataNode() → new DataNode(conf) → startDataNode()。

3.1 startDataNode() 核心初始化序列

步骤	操作	说明
1	initDataXceiver()	创建DataXceiverServer(TCP监听)，绑定流式数据传输端口
2	startInfoServer()	启动HTTP Web UI和REST API服务
3	initIpcServer()	创建IPC RPC Server，注册ClientDatanodeProtocol/InterDatanodeProtocol
4	初始化BlockScanner	创建块扫描管理器，管理所有VolumeScanner
5	初始化BlockPoolManager	创建BPOfferService(每个命名空间一个)，启动BPServiceActor线程
6	注册MXBean	注册DataNodeMXBean用于JMX监控

3.2 BPServiceActor完整生命周期

阶段	方法	说明
握手	connectToNNAndHandshake()	与NameNode建立连接，获取NamespaceInfo和blockPoolId
注册	register()	向NameNode注册DataNode，发送DatanodeRegistration
服务	offerService()	主循环：心跳→处理命令→IBR→全量块报告→缓存报告→等待
异常	handleRollingUpgradeStatus()	处理滚动升级状态同步
关闭	stop()	停止LifelineSender和CommandProcessingThread

3.3 DataNode关键接口实现

接口	用途
ClientDatanodeProtocol	客户端到DataNode的RPC协议(刷新、块恢复触发等)
InterDatanodeProtocol	DataNode之间的RPC协议(块恢复协调、副本信息交换)
DataNodeMXBean	JMX监控接口(集群ID、数据目录、磁盘使用率等)

接口	用途
ReconfigurableBase	支持运行时动态重配置(dfs.datanode.data.dir热添加删除存储卷)

四、块池管理层

块池管理层是DataNode与NameNode通信的核心。HDFS联邦下一个DataNode可服务多个命名空间，每个命名空间对应一个BPOfferService；HA下每个NameNode对应一个BPServiceActor线程。BlockPoolManager统一管理所有BPOfferService。

4.1 BPOfferService核心设计

- ReentrantReadWriteLock：保护bpRegistration、bpNSInfo、activeNN等共享状态，读多写少场景最优
- HA主备切换：updateActorStatesFromHeartbeat()根据心跳返回的NNHAStatusHeartbeat更新Active/Standby角色
- 命名空间隔离：每个BPOfferService管理独立的blockPoolId和注册状态，互不干扰
- BPServiceActorAction：命令模式接口，BPServiceActor通过bpServiceActorActions队列异步执行动作

4.2 BPServiceActor内部组件

组件	职责	说明
Scheduler	调度心跳/块报告/缓存报告	基于单调时间的调度器，支持抖动(jitter)防止雪崩
LifelineSender	HA生命线心跳	独立线程发送轻量级lifeline心跳，避免主心跳阻塞导致假死
CommandProcessingThread	异步命令处理	独立线程处理NN下发的DNA_*命令，避免阻塞主循环
IncrementalBlockReportManager	增量块报告管理	缓存块变更(add/delete/finalize)，按调度批量上报
RunningState	状态枚举	CONNECTING→INIT_FAILED→RUNNING→EXITED四种状态

4.3 NameNode下发命令类型

命令	说明
DNA_TRANSFER	复制块到其他DataNode(副本补充)
DNA_INVALIDATE	删除无效块(副本过多或过期)

命令	说明
DNA_RECOVERBLOCK	块恢复(Pipeline断裂后)
DNA_SHUTDOWN	关闭DataNode
DNA_REGISTER	要求DataNode重新注册
DNA_FINALIZE	完成升级
DNA_BALANCERBANDWIDTHUPDATE	更新均衡带宽限制
DNA_CACHE / DNA_UNCACHE	缓存/取消缓存块
DNA_ERASURE_CODING_RECOVERY	纠删码块重构

五、数据传输层

数据传输层负责处理HDFS客户端和其他DataNode的数据流请求。采用Reactor模式：DataXceiver Server负责accept，每个连接分派给DataXceiver线程处理。

5.1 DataXceiverServer — Reactor接受器

特性	实现	说明
监听端口	dfs.datanode.address(默认9866)	TCP流式数据传输端口
线程模型	每连接一线程(DataXceiver)	accept后创建DataXceiver,支持keepalive复用
均衡限流	BlockBalanceThrottler(Semaphore)	控制均衡操作最大并发数,读/写/传输三维度限流
连接管理	PeerServer + peers HashMap	跟踪所有活跃连接,支持释放过期连接

5.2 DataXceiver — 操作分派器

操作	方法	说明
读块	readBlock()	从本地磁盘读取并发送,委托BlockSender
写块	writeBlock()	接收上游数据写入本地,可能转发下游,委托BlockReceiver
复制块	copyBlock()	本地块复制到请求端,用于均衡/副本迁移
替换块	replaceBlock()	接收远端块写入本地替换
短路读	requestShortCircuitFds()	传递文件描述符给客户端实现短路读
传输块	transferBlock()	主动发起到其他DN的块传输

5.3 Pipeline写入流程




图5-1：数据写入Pipeline(三副本)

BlockReceiver是写入路径的核心。接收上游Packet，写入本地磁盘并转发下游。内含PacketResponder线程负责收集下游ACK并传回上游。

核心机制	说明
Packet粒度写入	每个Packet包含header+checksum+data,默认64KB
先写磁盘再转发	receivePacket():接收→写本地→转发下游→等待ACK
PacketResponder线程	独立线程等待下游ACK,合并本地ACK后传回上游
同步策略	syncOnClose时fsync刷盘; syncBehindWrites可选后台同步
校验和验证	每个chunk(默认512字节)验证CRC32/CRC32C校验和

5.4 BlockSender — 零拷贝读取

特性	说明
transferTo零拷贝	利用sendfile系统调用,数据直接从内核页缓存到Socket缓冲区
readahead预读	NativeIO.posixFadvise(WILLNEED)预读后续数据到内核页缓存
dropCacheBehind	NativeIO.posixFadvise(DONTNEED)读取后丢弃缓存,避免缓存污染
校验和发送	每个chunk的校验和紧跟数据发送,客户端验证完整性

六、块存储层 — 副本类型体系

块存储层通过SPI(Service Provider Interface)设计实现可插拔的块存储管理。FsDatasetSpi和FsVolumeSpi定义契约，FsDatasetImpl和FsVolumeImpl提供本地文件系统实现。

6.1 副本类型继承体系




图6-1：副本类型继承体系及状态转换

6.2 FsDatasetImpl核心组件

组件	类型	说明
volumes(FsVolumeList)	ArrayList	管理所有存储卷,支持热添加/移除
volumeMap(ReplicaMap)	Map<>	blockPoolId→(blockId→ReplicaInfo)二级映射
datasetRWLock	AutoCloseableLock	全局读写锁保护volumeMap和副本状态
asyncDiskService	FsDatasetAsyncDiskService	异步执行磁盘删除,避免阻塞主线程

6.3 FsVolumeImpl — 存储卷管理

特性	实现
存储介质类型	StorageType: DISK/SSD/ARCHIVE/RAM_DISK/NVDIMM
目录结构	/current/BP-xxx/current/finalized/subdir0~N/, /rbw/, /tmp/
VolumeChoosingPolicy	策略模式: RoundRobin(默认)/AvailableSpace可切换
blockPoolSlice	每个blockPool对应一个BlockPoolSlice管理独立目录

6.4 ReplicaBuilder — 建造者模式

ReplicaBuilder根据ReplicaState动态创建对应ReplicaInfo实例：FINALIZED→FinalizedReplica, RBW→ReplicaBeingWritten, RWR→ReplicaWaitingToBeRecovered, RUR→ReplicaUnderRecovery, TEMPORARY→LocalReplicaInPipeline。支持链式调用设置blockId, genStamp, volume等属性。

七、维护与扫描层

7.1 BlockScanner/VolumeScanner — 块完整性校验

特性	实现
扫描周期	dfs.block.scanner.volume.bytes.per.second(默认1MB/s)
优先扫描	可疑块优先: suspect块列表优先于常规扫描
扫描结果	ScanResultHandler: BAD_METADATA/BAD_CHECKSUM/NONE→上报NameNode
速率控制	循环缓冲区控制扫描速率,避免过度占用磁盘IO
管理结构	BlockScanner使用TreeMap按卷ID管理

7.2 DirectoryScanner — 磁盘与内存一致性

差异类型	含义	处理方式
磁盘有/内存无	块文件存在但ReplicaMap没有	添加到内存(addStoredBlock)
磁盘无/内存有	ReplicaMap有记录但文件缺失	从内存移除(removeStoredBlock)
元文件不匹配	元文件路径/校验和不匹配	更新元数据信息
GenStamp不一致	磁盘文件的GenerationStamp不同	以磁盘为准更新
块长度不一致	磁盘文件大小与numBytes不同	以磁盘为准更新

设计要点：分批reconcile避免长时间占锁；使用ForkJoinPool并行扫描多卷提升效率。

7.3 DiskBalancer — 本地磁盘均衡

DiskBalancer在DataNode本地不同磁盘间移动数据块，平衡各磁盘使用率。区别于HDFS Balancer(节点间均衡)，DiskBalancer专注单节点内磁盘均衡。核心组件：DiskBalancerPlan(JSON计划)、VolumePair(源卷+目标卷)、BlockMover(执行块移动)。

八、块恢复机制 — BlockRecoveryWorker

当NameNode检测到Pipeline异常中断时，选择一个DataNode作为恢复协调者，下发DNA_RECOVERBLOCK命令。BlockRecoveryWorker协调多DN将块恢复到一致状态。

8.1 块恢复流程

步骤	操作	说明
1	接收恢复命令	NameNode下发RecoverBlock命令,含block+参与DN列表
2	收集副本信息	协调者通过InterDatanodeProtocol获取每个DN的副本状态
3	计算恢复目标	选择最小GenerationStamp和blockLength作为恢复目标
4	同步所有副本	调用updateReplicaUnderRecovery()将所有DN副本截断/同步到目标
5	上报恢复结果	通过commitBlockSynchronization()向NameNode报告完成

8.2 连续块 vs 条带化块恢复

类型	实现类	特点
连续块恢复	RecoveryTaskContiguous	标准三副本恢复,所有副本截断到相同长度和GS
条带化块恢复	RecoveryTaskStriped	纠删码条带化块恢复,需考虑条带对齐和校验块

九、高级特性

9.1 纠删码 — ErasureCodingWorker

ErasureCodingWorker处理NameNode下发的纠删码重构任务。当数据/校验块丢失时，利用Reed-Solomon算法从剩余块重构丢失数据。

组件	说明
ErasureCodingWorker	纠删码工作器入口,管理重构任务队列和线程池
StripedReconstructor	抽象基类,定义条带化重构通用流程
StripedReader/Writer	从远端DN读取/写入条带化数据块
StripedBlockChecksumReconstructor	重构丢失块的校验和
RawErasureEncoder/Decoder	JNI调用ISA-L或Java实现的编解码器

9.2 短路读 — ShortCircuitRegistry

短路读允许同节点HDFS客户端绕过DataNode直接读取本地文件。ShortCircuitRegistry管理客户端和DataNode间的共享内存段和槽位(Slot)。通过Unix域套接字(DomainSocket)传递文件描述符(FD)给客户端。

9.3 FileIoProvider — IO代理/装饰器模式

FileIoProvider是所有文件IO操作的代理/装饰器。所有FsDatasetImpl/FsVolumeImpl的IO操作都通过FileIoProvider间接执行，在实际IO前后插入两类钩子：ProfilingFileIoEvents(性能统计)和FaultInjectorFileIoEvents(故障注入)。

十、核心流程时序分析

10.1 客户端写块完整流程

阶段一 Pipeline建立：Client→NN.addBlock()获取[DN1,DN2,DN3]→Client连接DN1发送OpWriteBlock(PIPELINE_SETUP_CREATE)→DN1连接DN2转发→DN2连接DN3转发→DN3返回SUCCESS逆向传播。

阶段二 数据传输：Client逐Packet发送→DN1(BlockReceiver)写本地+转发DN2→DN2写本地+转发DN3→DN3写本地+发ACK回DN2→DN2合并ACK回DN1→DN1回Client。

阶段三 完成：Client发送lastPacketInBlock→各DN finalizeBlock(RBW→FINALIZED)→各DN通过IBR上报FINALIZED给NameNode。

10.2 客户端读块流程

Client→NN.getBlockLocations()→选择最近DN发送OpReadBlock→DN(DataXceiver.readBlock)创建BlockSender→transferTo零拷贝发送→Client验证CRC→如果校验失败尝试下一个DN并报告坏块。

10.3 块恢复协调流程

NN检测Pipeline断裂→选择协调者DN下发DNA_RECOVERBLOCK→协调者(BlockRecoveryWorker)联系所有参与DN→各DN返回ReplicaRecoveryInfo(state,genStamp,numBytes)→协调者计算minLength→各DN.updateReplicaUnderRecovery()截断→协调者NN.commitBlockSynchronization()提交。

10.4 增量块报告(IBR)流程

FsDatasetImpl中块状态变更→调用notifyNamenodeReceived/Deleted/Finalized→IncrementalBlockReportManager缓存到PerStorageIBR→BPSERVICEActor主循环调用reportReceivedDeleteDBlocks()→发送到NameNode(BlockManager.processIncrementalBlockReport)→NN更新块→DN映射。

十一、设计模式总结

设计模式	应用场景	关键类	设计意图
门面模式	DataNode主入口	DataNode	统一入口管理所有子服务,隐藏内部复杂性
Reactor模式	数据传输服务	DataXceiverServer+DataXceiver	accept+dispatch,每连接一线程处理读写
职责链/Pipeline	写入数据流	BlockReceiver+PacketResponder	DN串行转发,ACK逆向传播
SPI接口模式	块存储抽象	FsDatasetSpi/FsVolumeSpi	存储实现可插拔,通过配置选择
策略模式	卷选择策略	VolumeChoosingPolicy	RoundRobin/AvailableSpace可切换
建造者模式	副本创建	ReplicaBuilder	根据State动态创建不同ReplicaInfo
命令模式	NN命令执行	BPServiceActorAction/ErrorReportAction	封装DNA_*为Action,异步队列执行
代理/装饰器	文件IO代理	FileIoProvider	透明插入性能统计和故障注入
读写锁	共享状态保护	BPOfferService/FsDatasetImpl	读多写少的并发控制
信号量	均衡限流	BlockBalanceThrottler(Semaphore)	控制均衡最大并发,保护磁盘IO
观察者模式	块变更通知	FsDatasetImpl→BPOfferService→IBR	块变更自动触发增量报告
模板方法	块恢复流程	RecoveryTaskContiguous/Striped	定义恢复骨架,子类实现差异

表11-1：DataNode核心设计模式一览(12种)

十二、关键场景调用链

12.1 DataNode 启动

```
DataNode.main() -> secureMain() -> createDataNode() -> instantiateDataNode() ->
new DataNode(conf) -> startDataNode() -> initDataXceiver() -> startInfoServer() ->
initIpcServer() -> BlockPoolManager.refreshNamenodes() -> BPOfferService.start() ->
BPServiceActor.run() -> connectToNNAndHandshake() -> register() -> offerService()
```

12.2 客户端写块

```
Client -> DataXceiverServer.accept() -> new DataXceiver(peer).start() ->
DataXceiver.writeBlock() -> FsDatasetImpl.createRbw() -> new BlockReceiver() ->
BlockReceiver.receiveBlock() -> receivePacket() -> ■■■ + ■■■■ ->
PacketResponder.run() -> ■■ACK + ■■■■
```

12.3 客户端读块

```
Client -> DataXceiverServer.accept() -> new DataXceiver(peer).start() ->
DataXceiver.readBlock() -> FsDatasetImpl.getBlockInputStream() ->
new BlockSender() -> BlockSender.sendBlock() -> transferToFully() (■■■)
```

12.4 心跳与块报告

```
BPServiceActor.offerService() -> scheduler.isHeartbeatDue() ->
sendHeartBeat() -> NN■■■■■■■■■■ -> processCommand() ->
CommandProcessingThread -> reportReceivedDeletedBlocks() -> blockReport()(■6h)
```

12.5 块恢复

```
NN■■■DNA_RECOVERBLOCK -> BPServiceActor.processCommand() ->
DataNode.recoverBlocks() -> BlockRecoveryWorker.recoverBlocks() ->
RecoveryTaskContiguous.recover() -> initReplicaRecovery() ->
updateReplicaUnderRecovery() -> commitBlockSynchronization()
```

12.6 磁盘均衡

```
hdfs diskbalancer -> DataNode.submitDiskBalancerPlan() ->
DiskBalancer.submitPlan() -> ■■JSON -> VolumePair■■ ->
BlockMover.run() -> FsDatasetImpl.moveBlockAcrossVolumes()
```

12.7 纠删码重构

```
NN■DNA_ERASURE_CODING_RECOVERY ->  
ErasureCodingWorker.processErasureCodingTasks() ->  
StripedReconstructor.reconstruct() -> StripedBlockReader.read() ->  
RawErasureDecoder.decode() -> StripedBlockWriter.write()
```

十三、子目录概览与核心源文件清单

13.1 子目录功能概览

子目录	文件数	核心职责	关键类
checker/	3	存储位置校验	StorageLocationChecker, ThrottledAsyncChecker
erasurecode/	10	纠删码重构	ErasureCodingWorker, StripedReconstructor
fsdataset/	28	块存储SPI接口	FsDatasetSpi, FsVolumeSpi, Replica, ReplicaInfo
fsdataset/impl/ /	25	存储默认实现	FsDatasetImpl, FsVolumeImpl, ReplicaMap
metrics/	4	JMX指标	DataNodeMetrics, DataNodePeerMetrics
web/	7	Web UI	DatanodeHttpServer, DatanodeWebHdfsMethods

13.2 根目录核心源文件清单(Top 25)

源文件	核心职责	关键特点
DataNode.java	DataNode主类(门面)	继承ReconfigurableBase,管理所有子服务
BPOfferService.java	块池/命名空间服务	RWLock保护,管理BPServiceActor,HA切换
BPServiceActor.java	NN通信线程	握手→注册→心跳→块报告完整生命周期
BlockReceiver.java	Pipeline写入核心	接收Packet+写磁盘+转发+PacketResponder
BlockSender.java	块读取发送	transferTo零拷贝+readahead+dropCacheBehind
DataXceiverServer.java	TCP监听(Reactor)	BlockBalanceThrottler信号量,三维度限流
DataXceiver.java	操作分派器	读/写/复制/替换/短路读,长连接复用
BlockRecoveryWorker.java	块恢复工作器	Contiguous+Striped两种恢复任务
BlockScanner.java	块扫描管理器	TreeMap管理VolumeScanner
VolumeScanner.java	单卷扫描线程	优先可疑块,循环缓冲区速率控制
DirectoryScanner.java	目录一致性扫描	ForkJoinPool并行,分批reconcile
DiskBalancer.java	磁盘均衡器	JSON计划,BlockMover,VolumePair

源文件	核心职责	关键特点
BlockPoolManager.java	BPOfferService管理器	联邦下命名服务动态增删改
DNConf.java	配置封装	集中管理所有DataNode配置参数
DataStorage.java	存储目录管理	格式化/版本升级/回滚/热插拔
FileIoProvider.java	IO代理(装饰器)	ProfilingEvents+FaultInjectorEvents
IncrementalBlockReportManager.java	增量块报告	PerStorageIBR缓存块变更
ShortCircuitRegistry.java	短路读管理	共享内存段+Slot管理
StorageLocation.java	存储位置封装	URI+StorageType(DISK/SSD/ARCHIVE)
Replica.java	副本顶层接口	blockId/genStamp/state/numBytes
ReplicaInfo.java	副本信息基类	extends Block implements Replica
LocalReplica.java	本地副本基类	封装本地磁盘文件操作
FinalizedReplica.java	已完成副本	FINALIZED状态,不可变
ReplicaBuilder.java	副本建造者	根据State创建不同ReplicaInfo
DataNodeMXBean.java	JMX监控接口	集群ID/磁盘使用率/存活DN

表13-2 : DataNode根目录核心源文件清单(Top 25)

十四、设计亮点与总结

14.1 设计亮点

- Pipeline写入架构：串行转发+ACK逆向传播，Packet粒度流式传输，最大化吞吐量
- 零拷贝读取：BlockSender使用transferTo(sendfile)系统调用，避免用户态拷贝
- Reactor模式数据传输：DataXceiverServer accept+DataXceiver dispatch，支持keepalive复用
- SPI可插拔存储：FsDatasetSpi/FsVolumeSpi接口设计，存储实现完全可替换
- 联邦+HA架构：BlockPoolManager→BPOfferService→BPServiceActor三层管理
- 建造者模式副本创建：ReplicaBuilder根据状态动态创建不同ReplicaInfo
- FileIoProvider装饰器：所有IO操作统一代理，透明插入性能统计和故障注入
- 增量块报告优化：IncrementalBlockReportManager缓存变更按批上报
- 三维度限流：BlockBalanceThrottler使用Semaphore控制均衡读/写/传输并发
- 分批reconcile：DirectoryScanner分批处理避免长时间占锁

14.2 质量评估

评估维度	评分	说明
架构分层	★★★★★	六层架构清晰,门面/管理/传输/存储/扫描/特性分离彻底
设计模式运用	★★★★★	12种设计模式精准运用,门面/Reactor/Pipeline/SPI/建造者等
可扩展性	★★★★★	SPI接口可插拔存储,策略模式可切换卷选择,命令模式可扩展
性能优化	★★★★★	零拷贝读/Pipeline写/增量报告/异步删除/三维度限流
并发控制	★★★★☆	读写锁+信号量+异步命令处理,部分场景仍有锁竞争
容错设计	★★★★☆	块恢复/目录扫描/坏块检测,但大文件恢复可能较慢

— 文档结束 —